

Три непростые игрушки

или как решать сложные задачи информатики, если на
знать, что они сложные ... и из информатики


Станислав Протасов

старший научный сотрудник университета Иннополис

Гирьки

Хочу вот такую игрушку!

Все грузики уравновешены на середине палочки



Игрушку привезли ...
в разобранном состоянии :(

- Грузики весом $[1] \times 2$, $[2] \times 1$, $[4] \times 3$, $[16] \times 1$, $[32] \times 1$
- Как собирать-то будем?

Сжимающее
префиксное
кодирование!

Кодирование

- Представление символов одного алфавита (например, букв) символами другого алфавита (например, двоичных символов)
 - Можно кодировать 1-1, 1-много, много-1, много-много
- $\text{ASCII}(\text{Z}) = \mathbf{90} = 1011010_2$
- $\text{MORSE}(\text{Z}) = \text{---} \cdot \cdot$
- $\text{PARITY}(001101_2) = 001101\mathbf{1}_2$

Код переменной длины

- Кодирование постоянной длины – Unicode (16), ASCII (8)
- Кодирование переменной длины – UTF-8 (8-16)
- Префиксное кодирование – ни одно слово кодирующего алфавита не является началом другого

Пример префиксного кода переменной длины

A = 0, B = 10, C = 11

Пример

- A – 1000
- Б – 1001
- В – 00
- Ж – 01
- X – 101
- У – 11


0001010111101 - ?

Почему сжимающий?

- Для кодирования алфавита в 6 символов кодом **фиксированной** длины нужно $\lceil \log_2(6) \rceil = 3$ бита
- А - 000
- Б - 001
- В - 010
- Ж - 011
- Х - 100
- У - 101


010011011011101100 – 18 бит

Как кодировать?




Собирать сверху вниз — код Шеннона-Фано (1948)

- «Вес» буквы — частота её повторений в тексте
- Делим буквы на 2 группы максимально близких по сумме «весов»
- Повторяем, пока в каждой группе не останется по одному символу (все буквы оказались в листьях дерева)





Клод Шэннон

- Отец теории информации, математик. Ввёл понятие **бит**
- Параллельно с Котельниковым предложил теорему о дискретном кодировании аналоговых сигналов. Благодаря этой теореме у нас есть цифровые форматы хранения музыки (началось с CD) и сотовая СВЯЗЬ




Собирать снизу вверх — код Хаффмана (1952)



Дэвид Хаффмана

- Первопроходец в сфере теории информации
- Внёс вклад в математическое origami и электронику
- Награждён бесчисленными наградами за создание **минимально-избыточных кодов**
 - Используется в MP3, ZIP (deflate), JPEG
 - Наследники – арифметическое кодирование, LZW (GIF)




И что дальше?

- Июнь 2016 – RAISR – алгоритм восстановления деталей на изображениях
- Март 2017 – Google опубликовала алгоритм Guetzli, который является улучшением JPEG, позволяет сжимать на 35% лучше

Карточный домик


Хочу построить карточный
домик, вот такой!



Нам завезли **N** карт. Сколько
уровней мы сможем построить?

Нужно больше уровней, милорд!

Вот столько уйдёт на каждый
уровень



А всего?

• $N =$

$$2^1 + 2^2 + 2^3 + \dots + 2^L =$$

$$\sum_{i=1}^L 2^i =$$

$$\frac{b * (1 - q^L)}{1 - q} =$$

$$\frac{2 * (1 - 2^L)}{1 - 2} = 2^{L+1} - 2$$

И чего?


- $N = 2^{L+1} - 2$

$$N + 2 = 2^{L+1} \quad | \quad \log_2$$

$$\log_2(N + 2) = L + 1$$




$$L = \left\lfloor \log_2 \left(\frac{N + 2}{2} \right) \right\rfloor$$

- Для 2 уровней хватит 6 карт
- Для 20 уровней нужно 2097150 карт
- Для 100 уровней потребуется уже **2535301200456458802993406410750** карт!
- **Удвоение** числа карт добавит нам всего **один уровень**



Мы доказали, что глубина совершенного двоичного дерева пропорциональна логарифму числа его узлов


- Похожее доказательство можно провести для AVL-, RB-, B-деревьев (деревья поиска)



- Также, с помощью этого факта можно показать, что есть предел скорости алгоритмов сравнительных сортировок, и этот предел $O(n \cdot \log(n))$.

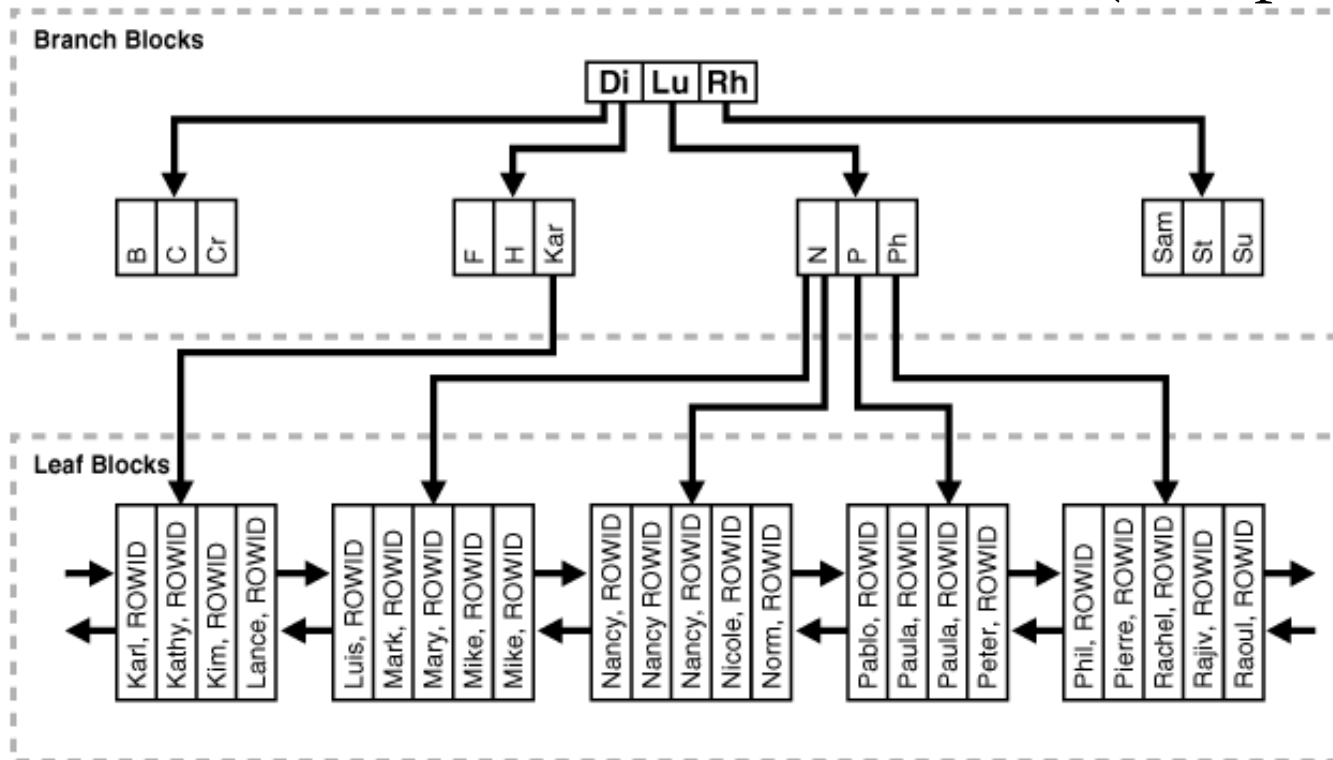
Что за деревья такие?

- Деревья поиска – деревья, у которых дети узлов упорядочены по возрастанию
- В двоичных деревьях поиска (AVL, RB) – левый ребёнок узла всегда меньше родителя, а правый – больше
- В таких деревьях время операций поиска/удаления/вставки элемента пропорционально длине пути от корня до него




Зачем нужны такие деревья?

- Организация множеств с большим числом элементов (вставка, поиск, удаление – быстрые)
- Организация индексов в базах данных (B-деревья)



АВЛ-деревья

- Адельсон-Вельский Г.М и Ландис В.М. (1962)



- А-В – искусственный интеллект, шахматная программа Каисса (чемпион 1974)
- Ландис – работал в области дифференциальных уравнений, автор 2 учебников


И что дальше?

- B^x Tree – в 2004 модификация B+ деревьев для эффективного хранения координат движущихся объектов
- Dancing Tree – в 2007 году Хансом Рейзером придумана модификация B+ дерева для индекса в Reiser4 (файловая система в Linux)

Угловая лестница


Угловая лестница

Хочу, чтобы у меня была в углу была стеклянная лестницы! Чтобы с обеих сторон выглядела одинаково! И вот такая в профиль!




Угловая лестница 3D

Придворная забава:
подняться снизу
вверх, делая только
шаги влево-вперёд
или вправо-вперёд.
Если наступаешь на
красный квадратик —
тебя казнят



Пара вопросов


- *Существуют ли пути, идущие через красный квадратик? Приведите пример*
- *Какова вероятность при прохождении случайным путём наступить на красный квадратик?*




Ответы на пару вопросов

- Да, конечно, например LRLRLRLRLR
- Вероятность события – это число всех путей ведущих через красный квадратик, делённое на число всех путей по лестнице
- $$P(\text{казни}) = \frac{C_{10}^5 * C_2^1}{C_{12}^6} = \frac{6}{11}$$

Посмотрим сверху?



Граф совместного исполнения!



Граф совместного исполнения

Модель, описывающая совместное исполнение двух функций, и позволяющая автоматически обнаруживать проблемы параллельного исполнения

- Deadlocks
- Data races
- ...

Что там за мелкий шрифт?

<code>mov eax, x; mov ebx, x</code>	<code>if (x*x</code>
<code>mul ecx</code>	<code>+</code>
<code>mov eax, y; mov ebx, y</code>	<code>y*y</code>
<code>mul edx</code>	
<code>[compare]</code>	<code><= 1.0) {</code>
<code>mov eax, count; inc eax</code>	<code>count++;</code>
<code>mov [<u>count</u>], eax</code>	
<code>...</code>	<code>}</code>

Что это было?

- Анализ параллельного кода — диагностика программ на потенциальные ошибки при многопоточном исполнении
- **Runtime**-анализ — диагностика программы путём запуска (Intel Parallel Studio)
- **Статический** анализ параллельного кода — диагностика **без запуска** программы

Статический анализ

Статический метод **анализа графа совместного исполнения** предложен ректором университета Иннополис Александром Тормасовым и применяется для статического анализа различных языков, поддерживающих представление LLVM



Что дальше?

- Имплементация эффективных методов статического анализа для различных проблем многопоточности
- Поддержка различных компиляторов и процессоров
- Счастье всем IDE
 - Снижение затрат компаний на исправление ошибок не очень внимательных программистов

Остались вопросы?

@sprotasov

s.protasov@innopolis.ru

https://t.me/origin_of_species